

Авторские права

© Postgres Professional, 2017–2024

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов, Алексей Береснев Фото: Олег Бартунов (монастырь Пху и пик Бхрикути, Непал)

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

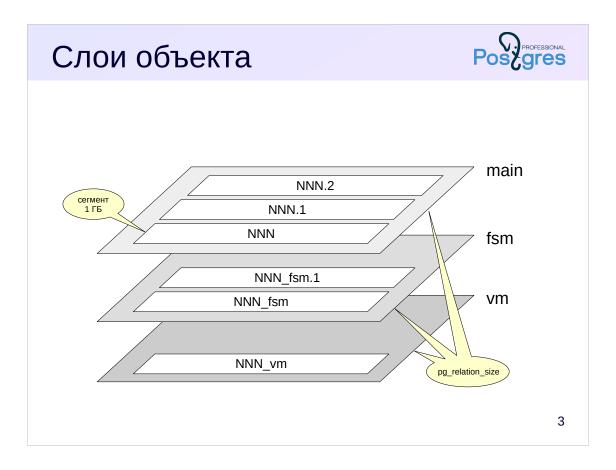
Темы



Файлы данных

Слои: данные, карты видимости и свободного пространства Длинные версии строк и TOAST

2



Обычно каждому объекту БД, хранящему данные (таблице, индексу, последовательности, материализованному представлению), соответствует несколько *слоев* (forks). Каждый слой содержит определенный вид данных.

Вначале слой содержит один-единственный файл. Имя файла состоит из числового идентификатора, к которому может быть добавлено окончание, соответствующее имени слоя.

Файл постепенно растет и, когда его размер доходит до 1 Гбайта, создается следующий файл этого же слоя. Такие файлы иногда называют сегментами. Порядковый номер сегмента добавляется в конец имени файла. Общий размер любого слоя показывает функция pg_relation_size.

Ограничение размера файла в 1 Гбайт возникло исторически для поддержки различных файловых систем, некоторые из которых не умеют работать с файлами большого размера. Установить другой размер можно только при сборке сервера из исходных кодов (--with-segsize).

Таким образом, одному объекту БД на диске может соответствовать несколько файлов. Для небольшой таблицы их будет 3, для индекса — два. Все файлы объектов, принадлежащих одному табличному пространству и одной БД, будут помещены в один каталог. Это необходимо учитывать, потому что файловые системы могут не очень хорошо работать с большим количеством файлов в каталоге.

Слои



Основной слой

собственно данные (версии строк) существует для всех объектов

Слой инициализации (init)

«пустышка» для основного слоя используется при сбое; только для нежурналируемых таблиц

Карта видимости (vm)

существует только для таблиц

Карта свободного пространства (fsm)

существует и для таблиц, и для индексов

4

Посмотрим теперь на типы слоев.

Основной слой — это собственно данные: версии строк таблиц или индексные записи. Имена файлов основного слоя совпадают с идентификатором. Основной слой существует для любых объектов.

Имена файлов слоя инициализации оканчиваются на «_init». Этот слой существует только для нежурналируемых таблиц (созданных с указанием UNLOGGED) и их индексов. Такие объекты ничем не отличаются от обычных, но действия с ними не записываются в журнал упреждающей записи. За счет этого работа с ними происходит быстрее, но в случае сбоя их содержимое невозможно восстановить. При восстановлении PostgreSQL просто удаляет все слои таких объектов и записывает слой инициализации на место основного слоя. В результате получается пустая таблица.

https://postgrespro.ru/docs/postgresql/16/storage-init

Слой vm (visibility map) — битовая карта видимости. Имена файлов этого слоя оканчиваются на «_vm». Слой существует только для таблиц; для индексов не поддерживается отдельная версионность.

Слой fsm (free space map) — *карта свободного пространства*. Имена файлов этого слоя оканчиваются на «_fsm». Этот слой существует и для таблиц, и для индексов.

Про две эти карты рассказывалось в модуле «Архитектура».

https://postgrespro.ru/docs/postgresql/16/storage-fsm

https://postgrespro.ru/docs/postgresql/16/storage-vm

Расположение файлов

```
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
Создадим таблицу и посмотрим на файлы, принадлежащие ей.
=> CREATE TABLE t(
 id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
 n numeric
CREATE TABLE
=> INSERT INTO t(n) SELECT id FROM generate_series(1,10_000) AS id;
=> VACUUM t:
VACUUM
Путь до основного файла относительно PGDATA можно получить функцией:
=> SELECT pg_relation_filepath('t');
pg relation filepath
base/16386/16388
(1 row)
Поскольку таблица находится в табличном пространстве pg default, путь начинается с base. Затем идет имя
каталога для базы данных:
=> SELECT oid FROM pg database WHERE datname = 'data lowlevel';
 oid
16386
(1 row)
Затем — собственно имя файла. Его можно узнать следующим образом:
=> SELECT relfilenode FROM pg class WHERE relname = 't';
relfilenode
       16388
(1 row)
Тем и удобна функция pg relation filepath, что выдает готовый путь без необходимости выполнять несколько
запросов к системному каталогу.
Посмотрим на файлы. Доступ к каталогу PGDATA имеет только пользователь ОС postgres, поэтому команда ls
выдается от его имени:
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/16388*
-rw----- 1 postgres postgres 450560 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16388
-rw----- 1 postgres postgres 24576 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16388 fsm
-rw----- 1 postgres postgres 8192 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16388_vm
Мы видим три слоя: основной слой, карту свободного пространства (fsm) и карту видимости (vm).
Аналогично можно посмотреть и на файлы индекса:
```

=> \d t

```
Column | Type | Collation | Nullable |
                                                  Default
| not null | generated always as identity
id | integer |
n | numeric |
Indexes:
   "t_pkey" PRIMARY KEY, btree (id)
=> SELECT pg relation filepath('t_pkey');
pg_relation_filepath
base/16386/16393
(1 row)
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/16393*
-rw----- 1 postgres postgres 245760 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16393
И на файлы последовательности, созданной для первичного ключа:
=> SELECT pg_relation_filepath(pg_get_serial_sequence('t','id'));
pg_relation_filepath
base/16386/16387
(1 row)
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/16387*
-rw----- 1 postgres postgres 8192 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16387
Временные таблицы хранятся так же, как и постоянные.
=> CREATE TEMP TABLE temp AS SELECT * FROM t;
SELECT 10000
=> VACUUM temp;
VACUUM
=> SELECT pg_relation_filepath('temp');
{\tt pg\_relation\_filepath}
base/16386/t4 16397
(1 row)
К имени файла добавляется префикс, соответствующий номеру схемы для временных объектов.
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/t4_16397*
-rw----- 1 postgres postgres 450560 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/t4 16397
-rw----- 1 postgres postgres 24576 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/t4_16397_fsm
-rw----- 1 postgres postgres 8192 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/t4 16397 vm
Существует полезное расширение oid2name, входящее в стандартную поставку, с помощью которого можно легко
связать объекты БД и файлы.
Можно посмотреть все базы данных:
student$ /usr/lib/postgresql/16/bin/oid2name
All databases:
   Oid Database Name Tablespace
 16386 data_lowlevel pg_default
       postgres pg_default
     5
 16385
             student pg_default
           template0 pg_default
template1 pg_default
     4
     1
```

Можно посмотреть все объекты в базе:

Table "public.t"

```
student$ /usr/lib/postgresql/16/bin/oid2name -d data_lowlevel
From database "data_lowlevel":
 Filenode Table Name
    16388
                t
    16397
                temp
Или все табличные пространства в базе:
student$ /usr/lib/postgresql/16/bin/oid2name -d data_lowlevel -s
All tablespaces:
  Oid Tablespace Name
 1663 pg_default
 1664
            pg_global
Можно по имени таблицы узнать имя файла:
student$ /usr/lib/postgresql/16/bin/oid2name -d data_lowlevel -t t
From database "data_lowlevel":
 Filenode Table Name
______
    16388
Или наоборот, по номеру файла узнать таблицу:
student$ /usr/lib/postgresql/16/bin/oid2name -d data_lowlevel -f 16388
From database "data_lowlevel":
 Filenode Table Name
    16388
```

Размер слоев

Размер файлов, входящих в слой, можно, конечно, посмотреть в файловой системе, но существует специальная функция для получения размера каждого слоя в отдельности:

TOAST



Версия строки должна помещаться на одну страницу

можно сжать часть полей можно вынести часть полей в отдельную toast-таблицу можно сжать и вынести одновременно

Toast-таблица

находится в схеме pg_toast (pg_toast_temp_N) поддержана собственным индексом содержит фрагменты «длинных» значений размером меньше страницы читается только при обращении к «длинному» полю имеет собственную версионность используется прозрачно для приложения

6

Любая версия строки в PostgreSQL должна целиком помещаться на одну страницу. Для «длинных» версий строк применяется технология TOAST — The Oversized Attributes Storage Technique. Она подразумевает несколько стратегий работы с «длинными» полями. Значение поля может быть сжато так, чтобы версия строки поместилась на страницу. Значение может быть убрано из версии и перемещено в отдельную служебную таблицу. Могут применяться и оба подхода: какие-то значения будут сжаты, какие-то — перемещены, какие-то — сжаты и перемещены одновременно.

Для каждой основной таблицы при необходимости создается отдельная toast-таблица (и к ней специальный индекс). Такие таблицы и индексы располагаются в отдельной схеме pg_toast и поэтому обычно не видны (для временных таблиц используется схема pg_toast_temp_N аналогично обычной pg_temp_N).

Версии строк в toast-таблице тоже должны помещаться на одну страницу, поэтому длинные значения хранятся порезанными на фрагменты. Из этих фрагментов PostgreSQL прозрачно для приложения «склеивает» необходимое значение.

Тоаst-таблица используется только при обращении к длинному значению. Кроме того, для toast-таблицы поддерживается своя версионность: если обновление данных не затрагивает «длинное» значение, новая версия строки будет ссылаться на то же самое значение в toast-таблице — это экономит место.

https://postgrespro.ru/docs/postgresql/16/storage-toast

TOAST

Access method: heap

```
В таблице t есть столбец типа numeric. Этот тип может работать с очень большими числами. Например, с такими:
=> SELECT length( (123456789::numeric ^ 12345::numeric)::text );
length
 99890
(1 row)
При этом, если вставить такое значение в таблицу, размер файлов не изменится:
=> SELECT pg relation size('t', 'main');
pg relation size
          450560
(1 row)
=> INSERT INTO t(n) SELECT 123456789::numeric ^ 12345::numeric;
INSERT 0 1
=> SELECT pg_relation_size('t','main');
pg_relation_size
         450560
(1 row)
Поскольку версия строки не может поместиться на одну страницу, она хранится в отдельной toast-таблице. Toast-
таблица и индекс к ней создаются автоматически для каждой таблицы, в которой есть потенциально «длинный» тип
данных, и используются по необходимости.
Имя и идентификатор такой таблицы можно найти следующим образом:
=> SELECT relname, relfilenode FROM pg_class WHERE oid = (
   SELECT reltoastrelid FROM pg_class WHERE oid = 't'::regclass
   relname | relfilenode
pg toast 16388 | 16391
(1 row)
Вот и файлы toast-таблицы:
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/16391*
-rw----- 1 postgres postgres 57344 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16391
-rw----- 1 postgres postgres 24576 июл 8 14:53
/var/lib/postgresql/16/main/base/16386/16391_fsm
Существуют несколько стратегий работы с длинными значениями. Название стратегии показывается в поле
Storage:
=> \d+ t
                                                  Table "public.t"
                                                                  | Storage |
Column | Type | Collation | Nullable |
                                                 Default
Compression | Stats target | Description
-----
       | integer |
id
                           | not null | generated always as identity | plain |
       | numeric |
                                                                   | main
                                      Τ
Indexes:
   "t_pkey" PRIMARY KEY, btree (id)
```

- plain TOAST не применяется (тип имеет фиксированную длину);
- extended применяется как сжатие, так и отдельное хранение;
- external сжатие не используется, только отдельное хранение;
- \bullet main такие поля обрабатываются в последнюю очередь и выносятся в toast-таблицу, только если сжатия недостаточно.

Стратегия назначается для каждого столбца при создании таблицы. Ее можно указать явно, а значение по умолчанию зависит от типа данных.

При необходимости стратегию можно впоследствии изменить. Например, если известно, что в столбце хранятся уже сжатые данные, разумно поставить стратегию external.

Просто для примера:

=> ALTER TABLE t ALTER COLUMN n SET STORAGE external;

ALTER TABLE

Эта операция не меняет существующие данные в таблице, но определяет стратегию работы с новыми версиями строк.



Как уже говорилось, размер отдельного слоя можно получить функцией pg_relation_size. Чтобы не суммировать размеры отдельных слоев, есть несколько функций, показывающих размеры таблицы:

- pg_table_size показывает размер таблицы и ее toast-части (toast-таблицы и обслуживающего ее индекса), но без обычных индексов.
 Эту же функцию можно использовать для вычисления размера отдельного индекса: и таблицы, и индексы являются отношениями, и, несмотря на название, функция принимает любое отношение.
- pg_indexes_size суммирует размеры всех индексов таблицы, кроме индекса toast-таблицы.
- pg_total_relation_size показывает полный размер таблицы, вместе со всеми ее индексами.

Размер таблицы

Размер таблицы, включая toast-таблицу и обслуживающий ее индекс:

Для получения размера отдельного индекса можно воспользоваться функцией pg_table_size. Toast-части у индексов нет, поэтому функция покажет только размер всех слоев индекса (main, fsm).

Сейчас у таблицы есть только индекс по первичному ключу, поэтому размер этого индекса совпадает со значением pg_indexes_size:

```
=> SELECT pg_table_size('t_pkey') AS t_pkey;
t_pkey
------
245760
(1 row)
```

Общий размер таблицы, включающий TOAST и все индексы:

Итоги



Объект представлен несколькими слоями Слой состоит из одного или нескольких файлов-сегментов Для «длинных» версий строк используется TOAST

10

Практика



- 1. Создайте нежурналируемую таблицу в пользовательском табличном пространстве и убедитесь, что для таблицы существует слой init.
 - Удалите созданное табличное пространство.
- 2. Создайте таблицу со столбцом типа text. Какая стратегия хранения применяется для этого столбца? Измените стратегию на external и вставьте в таблицу короткую и длинную строки.
 - Проверьте, попали ли строки в toast-таблицу, выполнив прямой запрос к ней. Объясните, почему.

11

1. Нежурналируемая таблица

```
student$ sudo -u postgres mkdir /var/lib/postgresql/ts_dir
=> CREATE TABLESPACE ts LOCATION '/var/lib/postgresql/ts_dir';
CREATE TABLESPACE
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
=> CREATE UNLOGGED TABLE u(n integer) TABLESPACE ts;
CREATE TABLE
=> INSERT INTO u(n) SELECT n FROM generate_series(1,1000) n;
INSERT 0 1000
=> SELECT pg_relation_filepath('u');
         pg relation filepath
pg tblspc/16386/PG 16 202307071/16387/16388
(1 row)
Посмотрим на файлы таблицы.
Обратите внимание, что следующая команда ls выполняется от имени пользователя postgres. Чтобы повторить
такую команду, удобно сначала открыть еще одно окно терминала и переключиться в нем на другого пользователя
команлой:
student$ sudo -i -u postgres
И затем в этом же окне выполнить:
postgres$ ls -l /var/lib/postgresql/16/main/pg_tblspc/16386/PG_16_202307071/16387/16388*
-rw----- 1 postgres postgres 40960 июл 8 15:01
/var/lib/postgresql/16/main/pg_tblspc/16386/PG_16_202307071/16387/16388
-rw----- 1 postgres postgres 24576 июл 8 15:01
/var/lib/postgresql/16/main/pg\_tblspc/16386/PG\_16\_202307071/16387/16388\_fsm
-rw----- 1 postgres postgres
                            0 июл 8 15:01
Удалим созданное табличное пространство:
=> DROP TABLE u;
DROP TABLE
=> DROP TABLESPACE ts;
DROP TABLESPACE
student$ sudo -u postgres rm -rf /var/lib/postgresql/ts_dir
2. Таблица с текстовым столбцом
=> CREATE TABLE t(s text);
CREATE TABLE
=> \d+ t
                                      Table "public.t"
Column | Type | Collation | Nullable | Default | Storage | Compression | Stats target |
Description
| | extended | |
s | text |
Access method: heap
```

По умолчанию для типа text используется стратегия extended.

Изменим стратегию на external:

Toast-таблица «спрятана», так как находится в схеме, которой нет в пути поиска. И это правильно, поскольку TOAST работает прозрачно для пользователя. Но заглянуть в таблицу все-таки можно:

Видно, что в TOAST-таблицу попала только длинная строка (два фрагмента, общий размер совпадает с длиной строки). Короткая строка не вынесена в TOAST просто потому, что в этом нет необходимости — версия строки и без этого помещается в страницу.

Практика+



- 1. Создайте базу данных.
 - Сравните размер базы данных, возвращаемый функцией pg_database_size, с общим размеров всех таблиц в этой базе. Объясните полученный результат.
- 2. В TOAST поддерживаются два метода сжатия: pglz и lz4. Проверьте средствами SQL, был ли PostgreSQL скомпилирован с поддержкой этих методов.
- 3. Создайте текстовый файл размером больше 10 Мбайт. Загрузите его содержимое в таблицу с текстовым полем, сначала без сжатия, а затем используя каждый из алгоритмов. Сравните итоговый размер таблицы и время загрузки данных для трех вариантов.

12

- 1. Список таблиц базы данных можно получить из таблицы pg_class системного каталога.
- 2. С помощью представления pg_config можно узнать, какие параметры были установлены скрипту configure при сборке ПО сервера. Строка, содержащая список параметров, велика; выделить необходимые параметры можно функцией string_to_table().
- 3. Чтобы получить текст для эксперимента, можно взять достаточно большой двоичный файл (например, исполняемый файл postgres) и преобразовать его в текст. Для преобразования можно использовать алгоритм Base32 (ключ -w0 отменяет переносы строк):

base32 -w0 < двоичный-файл > текстовый-файл

1. Сравнение размеров базы данных и таблиц в ней

```
=> CREATE DATABASE data_lowlevel;
CREATE DATABASE
=> \c data_lowlevel
You are now connected to database "data_lowlevel" as user "student".
```

Даже пустая база данных содержит таблицы, относящиеся к системного каталогу. Полный список отношений можно получить из таблицы pg_class. Из выборки надо исключить:

- таблицы, общие для всего кластера (они не относятся к текущей базе данных);
- индексы и toast-таблицы (они будут автоматически учтены при подсчета размера).

```
=> SELECT sum(pg_total_relation_size(oid))
FROM pg_class
WHERE NOT relisshared -- локальные объекты базы
AND relkind = 'r'; -- обычные таблицы

sum
------
7520256
(1 row)
```

Размер базы данных оказывается несколько больше:

Дело в том, что функция pg_database_size возвращает размер каталога файловой системы, а в этом каталоге находятся несколько служебных файлов.

```
=> SELECT oid FROM pg_database WHERE datname = 'data_lowlevel';
  oid
-----
16386
(1 row)
```

Обратите внимание, что следующая команда ls выполняется от имени пользователя postgres. Чтобы повторить такую команду, удобно сначала открыть еще одно окно терминала и переключиться в нем на другого пользователя командой:

```
student$ sudo -i -u postgres
```

И затем в этом же окне выполнить:

```
postgres$ ls -l /var/lib/postgresql/16/main/base/16386/[^0-9]*
-rw----- 1 postgres postgres 524 июл 8 15:02
/var/lib/postgresql/16/main/base/16386/pg_filenode.map
-rw----- 1 postgres postgres 159700 июл 8 15:02
/var/lib/postgresql/16/main/base/16386/pg_internal.init
-rw----- 1 postgres postgres 3 июл 8 15:02
/var/lib/postgresql/16/main/base/16386/PG VERSION
```

- pg_filenode.map отображение oid некоторых таблиц в имена файлов;
- pg_internal.init кеш системного каталога;
- PG_VERSION версия PostgreSQL.

Из-за того, что одни функции работают на уровне объектов базы данных, а другие — на уровне файловой системы, бывает сложно точно сопоставить возвращаемые размеры. Это относится и к функции pg tablespace size.

2. Поддержка методов сжатия TOAST

Представление pg_config показывает параметры, которые были переданы скрипту configure при сборке PostgreSQL.

```
=> SELECT * FROM (
 SELECT string to table(setting, '''') AS setting
 FROM pg_config WHERE name = 'CONFIGURE'
WHERE setting ~ '(lz|zs)';
  setting
 --with-lz4
 --with-zstd
(2 rows)
Какой метод сжатия TOAST используется по умолчанию?
=> \dconfig *toast*
 List of configuration parameters
       Parameter | Value
default_toast_compression | pglz
Какие методы можно применять?
=> SELECT setting, enumvals FROM pg_settings WHERE name = 'default_toast_compression';
 setting | enumvals
pglz | {pglz,lz4}
(1 row)
3. Сравнение методов сжатия
Сравним методы сжатия на примере текстовых данных.
Чтобы получить текст большого объема, возьмем исполняемый файл postgres и преобразуем его в текст с помощью
алгоритма Base 32, который применяется в электронной почте.
student$ sudo cat /usr/lib/postgresql/16/bin/postgres | base32 -w0 > /tmp/gram.input
Получившийся текстовый файл имеет достаточный размер.
student$ ls -l --block-size=K /tmp/gram.input
-rw-rw-r-- 1 student student 16148K июл 8 15:02 /tmp/gram.input
Создадим таблицу для загрузки текстовых данных.
Для столбца txt установим стратегию хранения EXTERNAL, которая допускает отдельное хранение, но не сжатие.
=> CREATE TABLE t (
 txt text STORAGE EXTERNAL
CREATE TABLE
Загрузим данные из текстового файла.
=> \timing on
Timing is on.
=> COPY t FROM '/tmp/gram.input';
COPY 1
Time: 615,616 ms
=> \timing off
Timing is off.
Проверим размер таблицы, включая TOAST.
=> SELECT pg_table_size('t')/1024;
 ?column?
   16808
(1 row)
```

Опустошим таблицу и зададим сжатие с помощью pglz.

```
=> TRUNCATE TABLE t;
TRUNCATE TABLE
=> ALTER TABLE t
ALTER COLUMN txt SET STORAGE EXTENDED,
ALTER COLUMN txt SET COMPRESSION pglz;
ALTER TABLE
Теперь используется стратегия EXTENDED, которая допускает как сжатие, так и отдельное хранение.
Снова загрузим данные.
=> \timing on
Timing is on.
=> COPY t FROM '/tmp/gram.input';
COPY 1
Time: 888,844 ms
=> \timing off
Timing is off.
=> SELECT pg table size('t')/1024;
 ?column?
   10368
(1 row)
Размер таблицы значительно уменьшился, но при этом заметно выросло время загрузки.
Снова опустошим таблицу и зададим теперь сжатие с помощью lz4.
=> TRUNCATE TABLE t;
TRUNCATE TABLE
=> ALTER TABLE t ALTER COLUMN txt SET COMPRESSION lz4;
ALTER TABLE
Еще раз загрузим данные и сравним.
=> \timing on
Timing is on.
=> COPY t FROM '/tmp/gram.input';
COPY 1
Time: 349,166 ms
=> \timing off
Timing is off.
=> SELECT pg_table_size('t')/1024;
 ?column?
    10656
(1 row)
Алгоритм lz4 слегка уступает pglz по степени сжатия, однако работает значительно быстрее.
Удалим текстовый файл.
student$ sudo rm -f /tmp/gram.input
```